

UNIVERSIDADE ESTADUAL DE CAMPINAS – UNICAMP
INSTITUTO DE MATEMÁTICA, ESTATÍSTICA E COMPUTAÇÃO CIENTÍFICA – IMECC

Disciplina: ME607 - Séries Temporais
Professor: Aluísio de Souza Pinheiro

Análise Espectral do Desenvolvimento Econômico Chinês: Uma Abordagem no Domínio da Frequência

Projeto 1: Modelo Teórico de Séries Temporais

Autor:
Eduardo Saegi de Souza Hsu
RA: 277142

CAMPINAS
2026

1 Introdução

Em 1949, após o término de sua guerra civil, a China figurava entre as nações mais pobres do mundo, com uma expectativa de vida que rondava a marca de apenas 30 anos. Atualmente, consolidou-se como uma das maiores potências econômicas globais, e sua expectativa de vida já se aproxima dos 80 anos. O modelo político e econômico chinês apresenta singularidades que desafiam as classificações binárias tradicionais entre capitalismo e socialismo. Acompanhar a evolução de indicadores como o Produto Interno Bruto (PIB) permite observar um processo de desenvolvimento em uma escala sem precedentes na história moderna.

Para compreender adequadamente as dinâmicas dessas séries temporais, é fundamental considerar marcos históricos e institucionais, como o ritmo ditado pelos Planos Quinquenais e a profunda transformação estrutural ocorrida após a abertura econômica liderada por Deng Xiaoping, a partir de 1978. Contudo, em contraste com as abordagens clássicas de séries temporais que operam estritamente no domínio do tempo, o presente projeto foca na fundamentação teórica de uma abordagem alternativa: a análise espectral, que transfere o estudo das observações para o domínio da frequência.

Nesse contexto, este trabalho tem como objetivo principal detalhar a metodologia matemática e estatística subjacente à análise espectral, ilustrando a sua aplicação na investigação de ciclos em séries temporais. Especificamente, o relatório busca apresentar as suposições teóricas necessárias para a validade do modelo, discutir os possíveis problemas encontrados em dados reais como a não-estacionariedade e as transformações matemáticas exigidas e avaliar criticamente as vantagens, desvantagens e limitações da análise no domínio da frequência, especialmente em contraposição aos modelos paramétricos tradicionais (como a família ARIMA). Para ilustrar a teoria, os conceitos serão aplicados preliminarmente sobre dados históricos macroeconômicos da China [1].

2 Fundamentação Teórica e Metodologia

A análise espectral representa uma mudança de paradigma em relação à modelagem tradicional de séries temporais. Enquanto a modelagem clássica no domínio do tempo (como a metodologia Box-Jenkins para modelos da família ARIMA [2]) investiga a relação de dependência de uma observação contemporânea com seus valores passados, a análise espectral transpõe o problema para o domínio da frequência. Ou seja, ao utilizar a análise espectral, a principal motivação é identificar e quantificar periodicidades (ciclos) ocultas nos dados.

Neste trabalho, a formulação teórica da análise espectral será baseada na classe de processos estocásticos fracamente estacionários. Dado um processo estocástico estacionário $\{X_t\}$ com média zero e função de autocovariância $\gamma(\tau)$ absolutamente somável (assintoticamente independente), isto é:

$$\sum_{\tau=-\infty}^{\infty} |\gamma(\tau)| < \infty$$

temos que a função densidade espectral $f(\lambda)$ é definida como a transformada discreta de Fourier da função de autocovariância $\gamma(\tau)$:

$$f(\lambda) = \frac{1}{2\pi} \sum_{\tau=-\infty}^{\infty} \gamma(\tau) e^{-i\lambda\tau}, \quad -\pi \leq \lambda \leq \pi$$

Onde $e^{-i\lambda\tau}$:

$$e^{-i\lambda\tau} = \cos(\lambda\tau) - i\sin(\lambda\tau)$$

Nesta formulação, λ representa a frequência angular, τ é a defasagem temporal e i é a unidade imaginária ($i^2 = -1$). O uso dessa identidade matemática é exatamente o que permite projetar a função de autocovariância $\gamma(\tau)$ sobre uma base de ondas senoidais e cossenoidais. Essencialmente, a operação matemática atua como um "filtro"que avalia a similaridade entre a estrutura de dependência da série temporal e ondas puras em diferentes frequências λ.

Intuitivamente, esse mecanismo de projeção funciona por um princípio de ressonância matemática. Se a função de autocovariância oscilar no mesmo ritmo da onda pura que está sendo testada na equação, os picos e vales de ambas se alinharão. Ao serem multiplicados e somados, eles evitam o cancelamento algébrico e geram uma soma expressiva. Consequentemente, essa 'sintonia' com as funções trigonométricas resultará em uma amplitude elevada para a densidade espectral $f(\lambda)$ naquele exato ponto (um pico no gráfico), confirmando matematicamente a presença daquele ciclo oculto.

Essa formulação é possível pois a análise espectral permite decompor a própria série temporal em componentes senoidais e, consequentemente, decompor a sua função de autocovariância. A sequência de autocovariâncias $\gamma(\tau)$ pode ser perfeitamente recuperada a partir de $f(\lambda)$ utilizando a transformada inversa de Fourier:

$$\gamma(\tau) = \int_{-\pi}^{\pi} f(\lambda) e^{i\lambda\tau} d\lambda$$

Dessa forma, probabilisticamente, ambas as funções são ferramentas matemáticas equivalentes que contêm as mesmas informações sobre a dependência linear do processo, apenas vistas sob óticas diferentes. O espectro pode ser interpretado como a decomposição da variância do processo estocástico em diferentes bandas de frequência. Ao avaliarmos a equação inversa no ponto em que a defasagem é nula ($\tau = 0$), obtemos a variância total do processo:

$$\gamma(0) = \text{Var}(X_t) = \int_{-\pi}^{\pi} f(\lambda) d\lambda$$

Portanto, a área sob a curva de $f(\lambda)$ representa a variância total da série. Um pico proeminente no espectro para uma frequência λ específica indica que os ciclos associados àquele intervalo contribuem grandemente para a variância e a dinâmica do processo, evidenciando uma forte periodicidade nos dados.

Para fundamentar a análise no domínio da frequência, é importante mencionar o Teorema de Representação Espectral (Cramér, 1942) [2]. Esse resultado estabelece que qualquer processo estocástico fracamente estacionário pode ser interpretado como uma superposição de componentes harmônicas em diferentes frequências.

Essa interpretação fornece a base conceitual da análise espectral: a série temporal pode ser decomposta em oscilações associadas a diferentes frequências, permitindo analisar como sua variância se distribui ao longo dessas componentes. Nesse contexto, a densidade espectral $f(\lambda)$ pode ser entendida como uma medida da contribuição de cada frequência para a variabilidade total do processo.

A fundamentação teórica apresentada até o momento pressupõe o conhecimento da função de autocovariância populacional e opera com realizações teóricas infinitas. No entanto, na prática empírica, como na análise das séries macroeconômicas, dispomos apenas de um conjunto finito de observações coletadas em intervalos de tempo discretos e igualmente espaçados, denotadas por $X_1, X_2, \ldots, X_N$.

Para adaptar a análise a essas restrições amostrais, utilizamos a Transformada Discreta de Fourier (DFT). A DFT mapeia a série temporal de tamanho finito do domínio do tempo para o domínio da frequência. Em vez de avaliar um espectro contínuo, a DFT opera nas chamadas frequências fundamentais (ou frequências de Fourier), definidas por $\lambda_j = 2\pi j/N$, onde j representa os harmônicos ($j = 0, 1, \ldots, N-1$). A transformação é dada por:

$$d(\lambda_j) = \frac{1}{\sqrt{N}} \sum_{t=1}^{N} X_t e^{-i\lambda_j t}$$

O termo $d(\lambda_j)$ representa a amplitude complexa associada à frequência λ_j. Como lidamos com uma amostra finita, o algoritmo realiza uma varredura testando apenas essas frequências discretas pré-definidas (j). Quando a varredura encontra uma frequência que se ajusta aos dados observados, a amplitude complexa $d(\lambda_j)$ captura a força dessa oscilação. É a partir dessa transformada discreta que o estimador empírico do espectro (o periodograma) é derivado computacionalmente, sendo definido essencialmente como o módulo ao quadrado da DFT, o que reflete a intensidade da ressonância encontrada

$$I(\lambda_j) = |d(\lambda_j)|^2$$

Graças ao algoritmo da Transformada Rápida de Fourier (FFT - Fast Fourier Transform), o cálculo numérico dessas integrais discretas é extremamente otimizado, o que viabiliza a análise espectral em softwares estatísticos modernos.

2.1 Estimação do Espectro: O Periodograma e a Necessidade de Suavização

Na prática, a densidade espectral teórica $f(\lambda)$ é desconhecida, pois dispomos apenas de uma realização finita da série temporal, denotada por $X_1, X_2, \ldots, X_N$. Para estimar o espectro a partir de dados amostrais, o estimador natural é o periodograma. O periodograma, denotado por $I(\lambda)$, é definido como:

$$I(\lambda) = \frac{1}{2\pi N} \left| \sum_{t=1}^{N} X_t e^{-i\lambda t} \right|^2$$

Avaliando o periodograma nas frequências de Fourier, $\lambda_j = 2\pi j/N$, obtemos uma medida descritiva da proporção da variância da amostra que pode ser atribuída a cada componente cíclica de frequência λ_j. Contudo, do ponto de vista da inferência estatística, o uso do periodograma bruto apresenta uma limitação crítica. Embora $I(\lambda)$ seja um estimador assintoticamente não viciado para $f(\lambda)$, isto é, sua esperança converge para o verdadeiro valor do espectro quando $N \to \infty$, ele é um estimador inconsistente.

A variância do periodograma não tende a zero com o aumento do tamanho da amostra; ao contrário, ela permanece aproximadamente constante (proporcional a $f^2(\lambda)$). Isso ocorre porque o número de frequências cresce com o tamanho da amostra, impedindo a redução da variabilidade do estimador em cada frequência individual. Consequentemente, o gráfico do periodograma exibe flutuações bruscas e um comportamento errático, dificultando a identificação dos verdadeiros picos espectrais. Para mitigar esse problema e obter um estimador consistente da densidade espectral, é necessário realizar uma suavização do periodograma.

O método mais comum consiste em aplicar uma média ponderada sobre valores adjacentes do periodograma ao redor da frequência de interesse, utilizando uma janela espectral $W(\cdot)$ [2]:

$$\hat{f}(\lambda) = \int_{-\pi}^{\pi} W(\lambda - \omega) I(\omega) d\omega$$

Essa operação de convolução sacrifica uma parcela da resolução espectral (introduzindo um pequeno viés) em troca de uma redução significativa na variância do estimador. Intuitivamente, a aplicação dessa janela atua como um filtro de médias móveis operando diretamente sobre o gráfico do espectro. Ao ponderar os valores adjacentes, o procedimento atenua as flutuações bruscas (espúrias) decorrentes do tamanho finito da amostra. Isso permite que a verdadeira estrutura cíclica subjacente, os picos

genuínos, se destaque visualmente do ruído de fundo, sacrificando uma pequena parcela da resolução (introduzindo viés) em prol da consistência estatística.

Na literatura estatística, destacam-se diversas escolhas para a função de ponderação, como as janelas de Bartlett, Daniell, Tukey-Hanning e Parzen. A escolha do grau de suavização (tamanho da janela ou bandwidth) é um passo crucial na modelagem empírica, exigindo um equilíbrio entre a suavidade da curva estimada e a fidelidade aos ciclos presentes nos dados.

2.2 Testes Formais para Periodicidade

A inspeção visual do periodograma (ou de sua versão suavizada) é uma etapa exploratória essencial; contudo, ela carece de rigor estatístico para a tomada de decisão. Devido à variabilidade amostral, o periodograma de qualquer série temporal finita exibirá picos em determinadas frequências, mesmo que os dados sejam gerados por um processo puramente aleatório. Portanto, torna-se indispensável a aplicação de testes de hipóteses para verificar se um pico proeminente reflete uma periodicidade genuína ou se é mero artifício do ruído estatístico.

O problema é usualmente formulado testando-se a hipótese nula (H_0) de que a série temporal é um ruído branco gaussiano (ausência de ciclos estruturais) contra a hipótese alternativa (H_1) de que a série é composta por uma ou mais componentes periódicas determinísticas sobrepostas a um ruído branco. Um dos procedimentos mais clássicos e rigorosos para esta finalidade é o Teste de Fisher (1929) [2] para periodicidades ocultas.

A estatística de teste proposta por Fisher baseia-se na razão entre a ordenada máxima do periodograma e a soma de todas as ordenadas calculadas nas frequências de Fourier. Formalmente, a estatística g é definida como:

$$g = \frac{\max_{1 \leq j \leq m} I(\lambda_j)}{\sum_{j=1}^{m} I(\lambda_j)}$$

onde m representa o número total de frequências de Fourier avaliadas na amostra. Para uma série temporal de tamanho finito N, esse valor é tipicamente definido como $m = \lfloor (N-1)/2 \rfloor$, o que engloba as frequências fundamentais no intervalo $(0, \pi)$, excluindo-se a frequência zero.

Intuitivamente, a estatística g avalia se a 'energia' concentrada na frequência dominante é grande o suficiente para se destacar do ruído global da série. Ela mensura a proporção da variância máxima do periodograma (o maior pico) em relação à soma de todas as variações (o ruído total). Sob a hipótese nula de ruído branco, se essa proporção for estatisticamente improvável de ter sido gerada por puro acaso estatístico (ultrapassando o valor crítico g_α), rejeita-se H_0, atestando que aquele pico representa uma periodicidade estrutural verdadeira.

2.3 Filtros Lineares e a Função de Transferência

Uma das principais vantagens da análise espectral é a simplicidade com que descreve o efeito de transformações lineares sobre séries temporais. Enquanto, no domínio do tempo, a aplicação de filtros envolve operações de convolução, no domínio da frequência essa operação se reduz a uma multiplicação direta, o que facilita significativamente a interpretação dos resultados.

Essa propriedade é particularmente relevante em séries macroeconômicas, como o Produto Interno Bruto (PIB), que frequentemente apresentam tendências de longo prazo e, portanto, não satisfazem diretamente a condição de estacionariedade. No domínio da frequência, essas tendências concentram a variância na frequência nula ($\lambda = 0$), dificultando a identificação de ciclos econômicos. Para contornar esse problema, utilizam-se filtros lineares, que permitem destacar as componentes de interesse da série.

De forma geral, um filtro linear transforma a série original $\{X_t\}$ em uma nova série $\{Y_t\}$ por meio de combinações lineares de seus valores ao longo do tempo:

$$Y_t = \sum_{j=-\infty}^{\infty} a_j X_{t-j}$$

No domínio da frequência, o efeito desse filtro é descrito de maneira simples: o espectro da série filtrada é obtido multiplicando o espectro original por uma função que atua como amplificadora ou atenuadora de determinadas frequências:

$$f_Y(\lambda) = |H(\lambda)|^2 f_X(\lambda)$$

onde $H(\lambda)$ é a função de transferência do filtro, definida como a transformada de Fourier dos coeficientes do filtro:

$$H(\lambda) = \sum_{j=-\infty}^{\infty} a_j e^{-i\lambda j} \tag{1}$$

Assim, $|H(\lambda)|^2$ determina quais frequências são enfatizadas ou suprimidas pelo filtro.

A grande vantagem analítica dessa formulação reside na conversão da operação de convolução temporal em um simples produto algébrico. No domínio do tempo, filtrar a série exige o cálculo de médias e defasagens ao longo de toda a amostra (convolução). Contudo, como o espectro já decompõe a série em ondas puras independentes, a função de transferência $|H(\lambda)|^2$ atua apenas como um fator de 'ganho' direto. Ela determina o peso numérico exato com que cada banda de frequência será enfatizada (valores altos) ou suprimida (valores próximos a zero) no espectro resultante, simplificando drasticamente o tratamento de tendências e sazonalidades.

Um exemplo importante é o operador de primeira diferença, definido por $Y_t = X_t - X_{t-1}$, amplamente utilizado para remover tendências. Nesse caso, o filtro elimina completamente a frequência zero, reduzindo a influência de componentes de longo prazo e destacando flutuações de curto prazo. Dessa forma, ele atua como um filtro passa-alta.

De maneira geral, diferentes tipos de filtros podem ser construídos para finalidades específicas: filtros passa-baixa suavizam a série, enquanto filtros passa-banda permitem isolar ciclos econômicos de interesse. Essa flexibilidade torna a análise espectral uma ferramenta particularmente útil na investigação de dinâmicas macroeconômicas.

2.4 Dualidade Diagnóstica

A distinção entre as metodologias torna-se ainda mais evidente ao compararmos as ferramentas visuais de diagnóstico de cada domínio: os correlogramas (Função de Autocorrelação - FAC e Função de Autocorrelação Parcial - FACP) no domínio do tempo, e o periodograma (ou densidade espectral teórica) no domínio da frequência. Sendo a densidade espectral a transformada de Fourier da autocovariância, ambas as ferramentas contêm, teoricamente, a mesma informação sobre a dependência linear do processo estocástico.

A superioridade dos correlogramas manifesta-se na identificação da ordem paramétrica dos modelos. Processos de Médias Móveis, $MA(q)$, possuem uma FAC que se trunca abruptamente após o lag q, enquanto processos Autoregressivos, $AR(p)$, exibem o mesmo comportamento de truncamento em sua FACP após o lag p. Essas assinaturas visuais claras são o pilar da identificação de modelos Box-Jenkins.

O espectro, em contrapartida, é pouco informativo para determinar a ordem exata p ou q de um modelo, pois não exibe pontos de corte abruptos. No entanto, sua superioridade revela-se na identificação imediata da natureza da dinâmica temporal, capturando a distribuição da variância:

Processos Autoregressivos (AR): apresentam espectros altamente dinâmicos e com picos proeminentes. Um modelo $AR(1)$, com um parâmetro positivo ($\phi_1 > 0$), comum em séries macroeconômicas de forte inércia, a FAC apresenta decaimento exponencial lento e suave. Isso se traduz em um espectro com a massa de variância fortemente concentrada nas baixas frequências (próximo a $\lambda = 0$). Inversamente, se $\phi_1 < 0$, a FAC alterna de sinal a cada defasagem, e o espectro revela um pico maciço em altas frequências (próximo a $\lambda = \pi$), diagnosticando um processo de rápida oscilação e reversão à média.

Processos de Médias Móveis (MA): devido à sua natureza de memória curta, seus espectros correspondentes são caracterizados por curvas notavelmente mais suaves e achatadas. Esse processo atua matematicamente de forma análoga a um filtro linear simples de alisamento, resultando em um espectro que distribui a variância de maneira mais uniforme. Contudo, devido à convenção de sinal, o espectro será dominado por altas frequências se $\theta_1 > 0$ ou por baixas frequências se $\theta_1 < 0$, manifestando-se de

forma muito menos pronunciada do que em modelos autoregressivos.

Essa dualidade diagnóstica reforça a complementaridade das abordagens: enquanto a FAC/FACP são ferramentas projetadas para a frugalidade paramétrica (identificar quantos coeficientes estimar), a densidade espectral é a ferramenta definitiva para o diagnóstico físico e econômico do processo (identificar o peso relativo das tendências, ciclos de negócios e ruídos de alta frequência na composição da série analisada).

3 Aplicação Preliminar: A Dinâmica Espectral do Crescimento Chinês

Para ilustrar a formulação teórica desenvolvida nas seções anteriores, os conceitos de análise no domínio da frequência foram aplicados à série do Produto Interno Bruto (PIB) real da China, em frequência anual [1]. As rotinas computacionais foram implementadas no ambiente estatístico R [3].

Conforme discutido na seção sobre filtros lineares, a série original do PIB em níveis apresenta uma forte tendência explosiva, o que concentraria a variância na frequência nula e inviabilizaria a análise espectral (Figura 1). Para induzir a estacionariedade, aplicou-se o filtro da primeira diferença logarítmica, resultando na série de taxas de crescimento (Figura 2), que orbita em torno de sua média histórica.

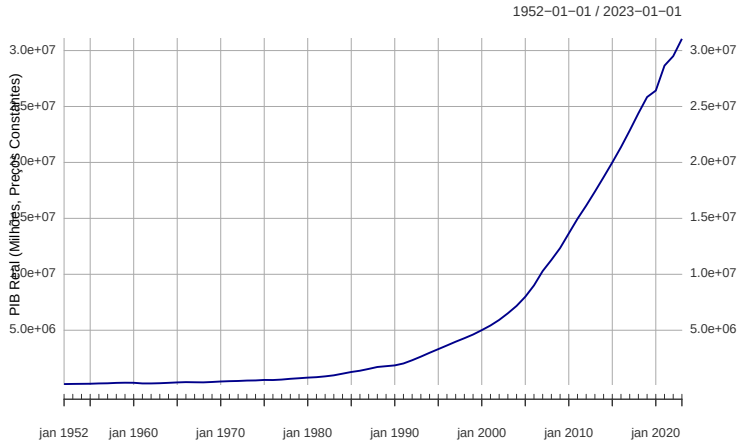


Figura 1: Série original do Produto Interno Bruto (PIB) real da China (níveis).

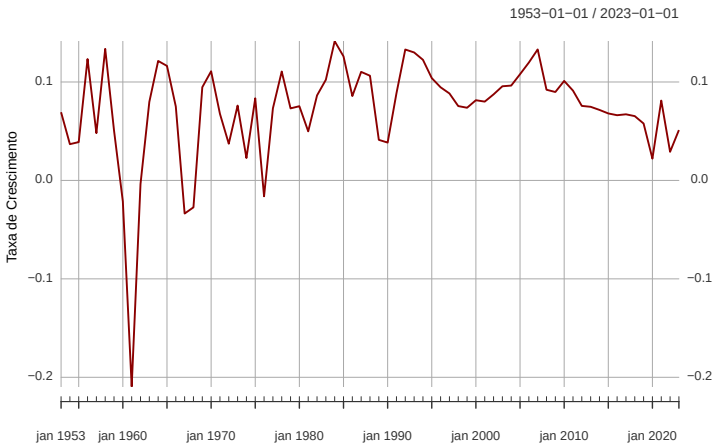


Figura 2: Série estacionarizada: Taxa de crescimento anual do PIB chinês.

A necessidade teórica de suavização do espectro, discutida na formulação metodológica, torna-se visualmente evidente ao analisarmos o estimador empírico inicial. A Figura 3 apresenta o periodograma bruto calculado para a série das taxas de crescimento do PIB chinês. Conforme previsto pela teoria assintótica, o estimador sem aplicação de filtros exibe alta variância e flutuações erráticas, caracterizando-se pela presença de múltiplos picos espúrios. Esse comportamento ruidoso inviabiliza a distinção clara entre a verdadeira estrutura cíclica macroeconômica e o mero ruído amostral inerente aos dados finitos. Essa limitação estrutural corrobora a exigência da aplicação de uma janela espectral na etapa subsequente, passo indispensável para garantir a consistência estatística do diagnóstico.

A dualidade teórica entre o domínio do tempo e da frequência torna-se evidente ao inspecionar a Função de Autocorrelação (FAC) lado a lado com o periodograma suavizado da taxa de crescimento (Figura 4). A suavização, realizada por meio de uma janela modificada de Daniell, foi necessária para garantir a consistência do estimador espectral empírico, mitigando o comportamento errático do periodograma bruto e revelando a estrutura latente da série.

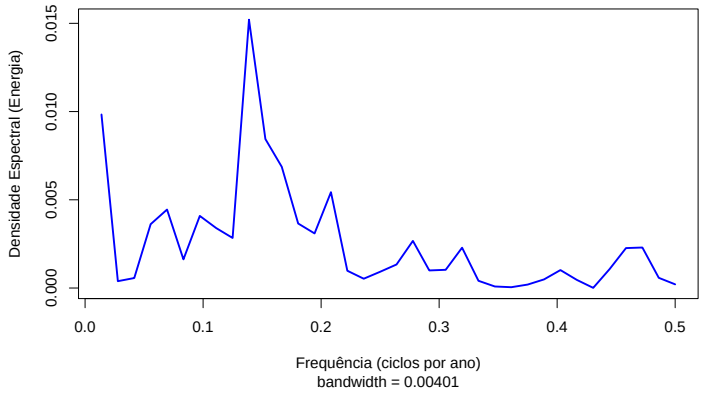


Figura 3: Periodograma bruto da taxa de crescimento anual do PIB chinês. O gráfico ilustra a inconsistência do estimador natural, evidenciada pela alta variância e pela proliferação de picos secundários que dificultam a identificação do ciclo principal.

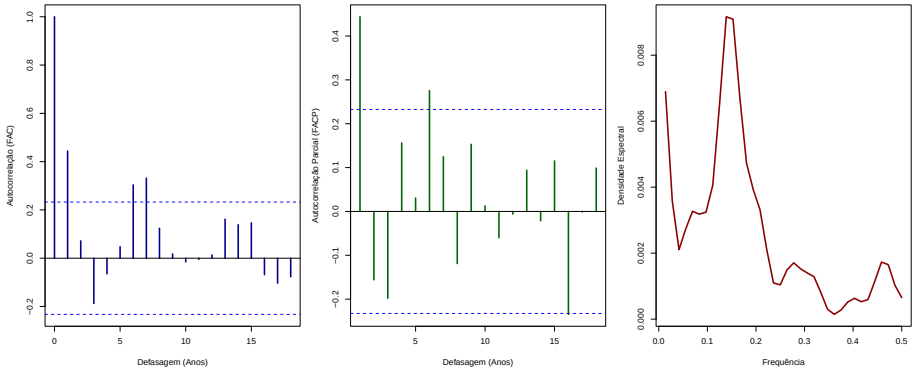


Figura 4: Dualidade diagnóstica: Correlogramas no domínio do tempo (FAC à esquerda e FACP ao centro) contrastados com a Densidade Espectral Suavizada no domínio da frequência (à direita)..

A inspeção conjunta dos correlogramas e da densidade espectral (Figura 4) revela a complexidade da dinâmica do crescimento chinês. No domínio do tempo, a FAC e a FACP exibem uma estrutura que ultrapassa a inércia de curtíssimo prazo. Embora o primeiro lag seja proeminente, indicando uma forte memória autoregressiva imediata, observa-se o ressurgimento de possíveis correlações significativas entre as defasagens 6 e 8.

Esse fenômeno é a representação, no domínio do tempo, da periodicidade identificada de forma muito mais nítida no domínio da frequência. Enquanto no tempo

essas correlações tardias podem ser confundidas com ruído ou exigir modelos de alta ordem para serem capturadas, o espectro consolida essa energia em um único pico central ao redor de $\lambda \approx 0,14$. Essa "ressonância"entre os domínios sugere que o ciclo de 7 anos não é um artefato estatístico, mas uma característica estrutural da série de taxas de crescimento do PIB.

Ao traduzir o eixo das frequências do periodograma suavizado para seus respectivos períodos em anos (Figura 5), observa-se um resultado empírico de alto valor analítico que contrasta com a expectativa teórica inicial. Foi traçada uma linha de referência vertical em $\lambda = 0,20$, representando a hipótese do ciclo político de 5 anos ditado pelos históricos Planos Quinquenais chineses. Contudo, o pico de densidade espectral, a maior concentração de variância da série, ocorre em uma frequência menor, situando-se no intervalo entre $\lambda \approx 0,14$ e $0,15$.

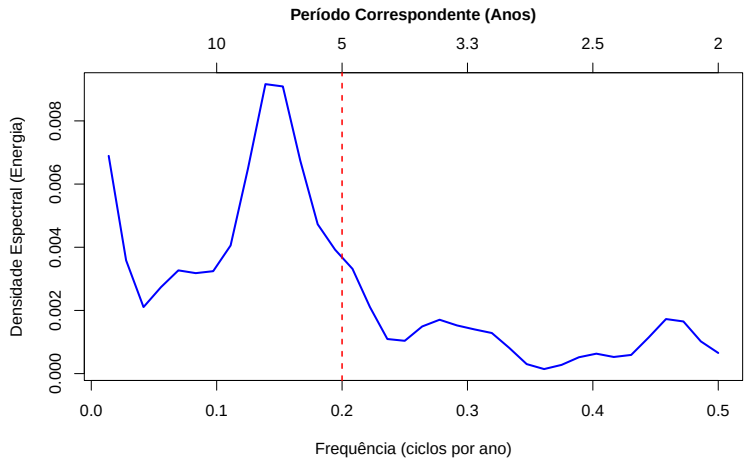


Figura 5: Densidade espectral detalhada. A linha tracejada indica o ciclo político teórico de 5 anos, enquanto o pico de energia revela um ciclo real mais longo.

Esse deslocamento traduz-se em um ciclo macroeconômico real com período aproximado de 6,5 a 7 anos. Essa constatação sugere que, apesar do forte planejamento estatal impor uma agenda quinquenal, a dinâmica real de acúmulo de capital, maturação de investimentos em infraestrutura e absorção de choques alonga a resposta do PIB. De toda forma, a abordagem no domínio da frequência provou-se altamente eficaz: em vez de impor um formato restrito aos dados (como na modelagem paramétrica no domínio do tempo), ela permitiu que a própria estrutura latente da série revelasse seu verdadeiro ritmo.

4 Discussão Crítica

A escolha metodológica pela análise no domínio da frequência não exclui a modelagem tradicional no domínio do tempo, cristalizada na metodologia Box-Jenkins (família ARIMA), mas oferece uma perspectiva analítica complementar. À luz da teoria exposta e da aplicação empírica realizada, é possível avaliar criticamente as forças e fraquezas desta abordagem.

A principal superioridade da análise espectral reside na sua capacidade não-paramétrica de revelar a estrutura latente dos dados sem a necessidade de pré-especificação de ordens de defasagem. Na modelagem SARIMA (ARIMA sazonal), a identificação de sazonalidades múltiplas ou complexas exige a estipulação exata de parâmetros sazonais (como P, D, Q), o que frequentemente conduz à superparametrização quando a série apresenta ciclos sobrepostos. A análise espectral, em contraste, permite que os próprios dados revelem as frequências dominantes.

Ademais, o espectro fornece uma interpretação física e econômica notavelmente mais direta. Enquanto os coeficientes de um modelo autoregressivo de alta ordem são de difícil interpretação isolada, um pico no periodograma oferece uma tradução macroeconômica imediata.

Observamos isso na prática, a análise da FAC e FACP poderia sugerir, à primeira vista, a especificação de um modelo $MA(1)$, $ARMA(1,1)$ ou $AR(1)$ para capturar a dependência linear. Contudo, tal modelo seria incapaz de descrever o ciclo macroeconômico de 7 anos identificado no espectro, uma vez que a memória de processos ARMA de baixa ordem decai exponencialmente para zero.

Para contemplar o ciclo de maturação chinês estritamente no domínio do tempo, o pesquisador seria forçado a abandonar o princípio da frugalidade, recorrendo a modelos de alta ordem ou a especificações sazonais rígidas ($SARIMA$). A análise espectral supera essa limitação ao identificar a periodicidade de forma não-paramétrica. Ela revela que o que parece ser uma estrutura de correlação complexa no tempo é, na verdade, uma oscilação cíclica bem definida na frequência, permitindo um diagnóstico físico do processo econômico que modelos paramétricos simplificados tenderiam a omitir ou subestimar.

Apesar de sua elegância para a detecção de ciclos, a análise espectral apresenta limitações teóricas e práticas severas, especialmente quando o objetivo primário da pesquisa é a previsão. Os modelos ARIMA são desenhados inerentemente com base na dependência condicional de uma observação em relação ao seu passado recente, o que torna a extrapolação probabilística de curto prazo um passo algébrico natural. O espectro, por focar no comportamento global de ondas que se estendem infinitamente, é consideravelmente menos instrumental para a geração de previsões pontuais precisas.

Outra limitação crítica é a rígida exigência de estacionariedade global. Séries com tendências estocásticas ou determinísticas fortes concentram uma energia desproporcional na frequência nula ($\lambda = 0$). Isso gera o fenômeno conhecido como vazamento espectral, onde a massa da variância de baixa frequência "vaza"e contamina o

restante do periodograma, ofuscando ciclos de negócios legítimos. Além disso, o estimador natural do espectro, o periodograma bruto, é estatisticamente inconsistente, exigindo séries temporais longas (amostras grandes) para que as técnicas de correção operem de forma eficaz.

Uma limitação empírica inerente a este estudo preliminar reside no tamanho restrito da amostra analisada. A teoria subjacente à análise espectral exige séries temporais consideravelmente longas para que seus estimadores atinjam consistência assintótica e alta resolução. No caso dos dados anuais do PIB chinês, essa restrição amostral reflete-se visualmente no periodograma suavizado por meio de uma expressiva concentração de energia residual nas proximidades da frequência nula ($\lambda \approx 0$).

Esse artefato indica que, apesar do filtro de primeira diferença suprimir teoricamente a energia em $\lambda = 0$, a série estacionarizada retém forte memória autorregressiva (inércia), o que concentra grande parte da variância natural em frequências muito baixas. Devido à restrição de tamanho da amostra, essa enorme massa de energia sofre vazamento espectral, borrando a região inicial do periodograma empírico e mascarando a identificação clara de ciclos mais sutis.

O Teste Clássico de Fisher para periodicidade assume uma hipótese nula de ruído branco, o que se prova inadequado para a taxa de crescimento do PIB chinês, cuja natureza é fortemente inercial. A aplicação direta de Fisher falharia, pois a variância dominante da inércia ofuscaria o ciclo de 7 anos. Ademais, aplicar um filtro passa-banda para forçar a série a um comportamento de ruído branco apenas para viabilizar o teste seria um artifício metodológico questionável.

Portanto, como a análise atual baseia-se fortemente na inspeção visual dos picos do periodograma suavizado, podendo o ciclo de 7 anos sugerido pelo periodograma ser apenas um artefato do estimador. Uma evolução inferencial necessária seria a incorporação de testes espectrais estendidos.

Para finalizar, é importante destacar que os resultados obtidos neste trabalho podem ser aprimorados com o uso de técnicas mais avançadas de análise espectral. Em particular, uma extensão natural seria a aplicação de testes espectrais formulados sob a hipótese de ruído colorido, como processos ARMA, em vez da hipótese restritiva de ruído branco. Isso permitiria uma avaliação mais realista da significância dos ciclos identificados, considerando a forte dependência temporal presente em séries macroeconômicas.

Além disso, melhorias na estimação do espectro também podem ser obtidas por meio do uso de janelas mais adequadas, ou mesmo de métodos como o multitaper, que reduzem a variância do estimador e minimizam o problema de vazamento espectral. Essas técnicas tornam a identificação de frequências dominantes mais confiável, especialmente em amostras curtas.

Dessa forma, embora a análise espectral apresentada já ofereça insights relevantes sobre a dinâmica cíclica da série estudada, sua evolução metodológica abre espaço para resultados mais robustos e estatisticamente fundamentados, consolidando o papel complementar da abordagem no estudo de séries temporais econômicas.

Referências

[1] Robert C. Feenstra, Robert Inklaar, and Marcel P. Timmer. The next generation of the penn world table. *American Economic Review*, 105(10):3150–3182, 2015. ISSN: 0002-8282.

[2] Pedro A. Morettin and Clélia M. C. Toloi. *Análise de Séries Temporais*. Blucher, São Paulo, 3 edition, 2018. ISBN: 978-85-212-1352-9.

[3] R Core Team. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria, 2023.